

Carga y transformacion

Paquetes

Carga de datos: ejemplo medioambiente y aire

Ozono

Datos minutales de concentración de ozono (O3) en aire ambiente.

```
ozono <- read_csv(here::here("clases/clase7/o3_01_2024_04_2024.csv"),  
                  locale = locale(encoding = "latin1"))
```

Rows: 291926 Columns: 5

-- Column specification -----

Delimiter: ","

chr (1): estacion

dbl (3): o3, longitud, latitud

dtm (1): fecha

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

Material particulado

Material particulado menor de 2,5 micras medido en estaciones automáticas

```
pm <- read_csv(here::here("clases/clase7/pm_2_5_01_2024_04_2024.csv"),  
               locale = locale(encoding = "latin1"))
```

```

Rows: 424779 Columns: 5
-- Column specification -----
Delimiter: ","
chr  (1): estacion
dbl  (3): pm2_5, longitud, latitud
dtm  (1): fecha

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.

```

Conteo vehicular en las principales avenidas de Montevideo

El sistema de conteo vehicular que utiliza el Centro de Gestión de Movilidad (CGM) para la medición de los volúmenes vehiculares que circulan por las arterias que se encuentran centralizadas, utiliza analíticas de video para la generación de los datos necesarios para la elaboración de planes y coordinaciones semafóricas. Los detectores miden el total de vehículos y su clasificación por largo de los mismos, por sentido de circulación, pudiendo discriminarse por carril dentro de cada sentido.

```

auto <- read_csv(here::here("clases/clase7/autoscope_04_2024_volumen.csv"),
                 locale = locale(encoding = "latin1"))

```

```

Rows: 3207345 Columns: 11
-- Column specification -----
Delimiter: ","
chr  (3): dsc_avenida, dsc_int_anterior, dsc_int_siguiente
dbl  (6): cod_detector, id_carril, latitud, longitud, volume, volumen_hora
date (1): fecha
time (1): hora

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.

```

Data profiling: id, nulos y duplicados

Información básica del dataset

```
str(ozono)
```

```

spc_tbl_ [291,926 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ fecha      : POSIXct[1:291926], format: "2024-01-01 00:00:00" "2024-01-
01 00:00:00" ...
 $ o3         : num [1:291926] 6 NA 8 NA 8 NA 10 NA 10 NA ...
 $ estacion: chr [1:291926] "ColÃ³n" "Curva de Maroñas" "ColÃ³n" "Curva de Maroñas" ...
 $ longitud: num [1:291926] -56.2 -56.1 -56.2 -56.1 -56.2 ...
 $ latitud  : num [1:291926] -34.8 -34.9 -34.8 -34.9 -34.8 ...
- attr(*, "spec")=
 .. cols(
 .. fecha = col_datetime(format = ""),
 .. o3 = col_double(),
 .. estacion = col_character(),
 .. longitud = col_double(),
 .. latitud = col_double()
 .. )
- attr(*, "problems")=<pointer: 0x00000201642f5750>

```

Identificador

Para el caso del ozono los datos se toman por estación (que tiene una ubicación geográfica, es decir, es una característica de la estación) y por fecha.

El identificador podría ser la fecha. ¿Por qué? Porque sirve para unir con otros datos.

También podría ser una combinación de fecha y estación.

1- Tenemos problemas con los valores de las estaciones

```
ozono[1:10,3]
```

```

# A tibble: 10 x 1
  estacion
  <chr>
1 ColÃ³n
2 Curva de Maroñas
3 ColÃ³n
4 Curva de Maroñas
5 ColÃ³n
6 Curva de Maroñas
7 ColÃ³n
8 Curva de Maroñas
9 ColÃ³n
10 Curva de Maroñas

```

```
unique(ozono$estacion)
```

```
[1] "ColÃ³n" "Curva de MaroÃ±as"
```

```
# 1. Creamos el diccionario de traducci3n (Busca = Reemplaza)
pauta_limpieza <- c(
  "Ã³" = "o",
  "Ã±" = "ni",
  "Ã¡" = "a",
  "Ã©" = "e",
  "Ã" = "i",
  "Ãº" = "u",
  "Ã" = "o",
  "Ã'" = "NI",
  "Ã" = "i" # Nota: a veces la 'i' sola se rompe asÃ, dÃjala al final de la lista
)

# 2. Aplicamos la limpieza a tu columna
ozono_limpio <- ozono %>%
  mutate(
    # Cambia 'tu_columna' por el nombre real de tu columna
    estacion = str_replace_all(estacion, pauta_limpieza)
  )
```

Valores faltantes

```
colSums(is.na(ozono))
```

fecha	o3	estacion	longitud	latitud
0	36159	0	0	0

La 3nica variable que tiene valores faltantes es la medici3n, por lo tanto se pueden eliminar los valores faltantes, ya que no eliminamos identificador (podrÃa discutirse si hay que eliminar fechas sin registro).

Quito los NA de todo el dataset (si hubieran mÃs columnas con NA tambi3n quita esa fila):

```
ozono_sinna <- ozono_limpio %>%  
  na.omit()
```

Quito los NA de columnas específicas:

```
ozono_sinna <- ozono_limpio %>%  
  filter(is.na(o3) != TRUE)
```

Duplicados

Para saber rápidamente el número total de filas repetidas en todo tu dataset:

```
ozono_sinna %>%  
  duplicated() %>%  
  sum()
```

```
[1] 0
```

Mostrar solo las filas que están repetidas y ver qué tienen dentro

```
# Si quieres ver TODAS las filas involucradas en el duplicado (la primera y sus copias):  
ozono_repetidas <- ozono_sinna %>%  
  filter(duplicated(.) | duplicated(., fromLast = TRUE))
```

Eliminar duplicados

```
# Conserva solo la primera aparición de cada fila única  
dataset_sindup <- ozono_sinna %>%  
  distinct()  
  
# Si quieres eliminar duplicados basados solo en una columna (ej. 'nombre_barrio')  
# y conservar el resto de las columnas del primer registro:  
dataset_sindup_columna <- ozono_sinna %>%  
  distinct(estacion, .keep_all = TRUE)
```

Tipos de datos y transformación de datos

Fechas

El formato “POSIXct” “POSIXt” representan el formato estándar para manejar fechas y horas exactas (lo que en programación se conoce como Timestamp o Datetime)

```
class(ozono$fecha)
```

```
[1] "POSIXct" "POSIXt"
```

1. ¿Qué es POSIXct? (La clase real) La ct significa calendar time (tiempo de calendario). Internamente, R guarda esta variable como un número entero: la cantidad de segundos que han pasado desde el 1 de enero de 1970 hasta ese momento. Al ser un número por dentro, es un formato extremadamente rápido y eficiente para hacer cálculos (por ejemplo, restar dos fechas para saber cuántas horas o días pasaron).
2. ¿Qué es “POSIXt”? (La clase heredada). Es una “superclase” virtual de R. Solo sirve para que R sepa que esa variable es un formato de tiempo y que puede usar con ella funciones de fechas (como sumarle días, extraer el mes, etc.)

Crear variables

```
ozono_new <- ozono_sinna %>%  
  mutate(  
    anio = lubridate::year(fecha),  
    mes  = lubridate::month(fecha),  
    hora = lubridate::hour(fecha)  
  )
```


Generación de información

Agregación mensual

```
ozono_mes <- ozono_new %>%  
  group_by(mes) %>%  
  summarise(  
    o3_medio_mes = mean(o3),  
    n_registros_mes = n())
```

Visualización

```
ozono_mes %>%
  ggplot(aes(x = mes, y = o3_medio_mes)) +
    geom_line(color = "blue", linewidth = 1) + # Une los puntos con una línea
    geom_point(color = "red", size = 3) +      # Dibuja los puntos individuales
    theme_minimal() +                          # Aplica un diseño limpio
    labs(
      title = "Concentración de Ozono en el ambiente, por mes, 2024",
      x = "Fecha",
      y = "Valores"
    )
)
```



Partes básicas de un gráfico:

- dataset
- variable eje x
- variable eje y
- tipo de gráfico
- títulos: del gráfico y nombres de los ejes

Información completa en Cheetsheet: <https://ggplot2.tidyverse.org/>

Análisis profundo: Agregación temporal: minutal -> horario -> diario

Pregunta central: al agregar, ¿qué estadístico representa el fenómeno?


- media: nivel típico
- máximo: episodios puntuales (sensible a errores del sensor)
- percentil 95: episodios altos pero robusto a picos aislados
- n: cuántos minutos respaldan el valor agregado (cobertura)

Horario

```
ozono_hora <- ozono_sinna %>%
  mutate(fecha_hora = floor_date(fecha, unit = "hour")) %>%
  group_by(estacion, fecha_hora) %>%
  summarise(
    media = mean(o3),
    maximo = max(o3),
    p95 = quantile(o3, 0.95),
    n_min = n(), # de un máximo de 60
    .groups = "drop"
  )
```

```
ozono_hora %>%
  ggplot(aes(x = fecha_hora, y = media)) +
  geom_line(color = "blue", linewidth = 1) + # Une los puntos con una línea
  geom_point(color = "red", size = 1) + # Dibuja los puntos individuales
  theme_minimal() + # Aplica un diseño limpio
  labs(
    title = "Concentración de Ozono en el ambiente, por hora, 2024",
    x = "Fecha",
    y = "Valores"
  )
```

Concentración de Ozono en el ambiente, por hora, 2024



Teoría estadística

```
source(here::here("clases/clase7/media_percentil.R"))
```

```
Warning in annotate("label", x = 163, y = c(0.0165, 0.0125, 0.0105, 0.008), :  
Ignoring unknown parameters: `label.size`
```


```
Warning in annotate("label", x = 1, y = c(0.93, 0.82, 0.74, 0.685, 0.6), :  
Ignoring unknown parameters: `label.size`
```

```
Warning in annotate("label", x = 300, y = 3.5, size = 3, label.size = 0.3, :  
Ignoring unknown parameters: `label.size`
```

```
media=31.76  p95=62.02  |  con picos: media=34.99  p95=63.30
```


pA

A. ¿Dónde están la media y el p95?




pB

B. El p95 como inversa de la distribución



C. 10 picos espurios entre 1450 datos




Diario

```
ozono_dia <- ozono_sinna %>%
  mutate(dia = as_date(fecha)) %>%
  group_by(estacion, dia) %>%
  summarise(
    media = mean(o3),
    maximo = max(o3),
    p95 = quantile(o3, 0.95),
    n_min = n(), # de un máximo de 1440
    .groups = "drop"
  )
```

```
ozono_dia %>%
  ggplot(aes(x = dia, y = media)) +
    geom_line(color = "blue", linewidth = 1) + # Une los puntos con una línea
    geom_point(color = "red", size = 1) + # Dibuja los puntos individuales
    theme_minimal() + # Aplica un diseño limpio
```


```
labs(
  title = "Concentración de Ozono en el ambiente, por hora, 2024",
  x = "Fecha",
  y = "Valores"
)
```



Las tres curvas cuentan historias distintas sobre el mismo día

```
ozono_dia %>%
  pivot_longer(c(media, p95, maximo), names_to = "estadistico", values_to = "o3") %>%
  ggplot(aes(x = dia, y = o3, color = estadistico)) +
  geom_line() +
  facet_wrap(~ estacion, ncol = 1, scales = "free_y") +
  theme_minimal() +
  labs(title = "Agregación diaria: media, p95 y máximo por estación",
       x = NULL, y = "O3 (µg/m³)")
```

Agregación diaria: media, p95 y máximo por estación



El estadístico normativo: máximo diario de la media móvil de 8 horas Las guías OMS (2021) para O3 usan el máximo diario de la media móvil de 8 h. Una media móvil requiere una grilla horaria COMPLETA: si faltan horas, la ventana de 8 posiciones deja de ser una ventana de 8 horas.

```
grilla_horaria <- seq(min(ozono_hora$fecha_hora), max(ozono_hora$fecha_hora), by = "hour")
```

```
ozono_8h <- ozono_hora %>%
  select(estacion, fecha_hora, media) %>%
  complete(estacion, fecha_hora = grilla_horaria) %>% # inserta NA en horas ausentes
  arrange(estacion, fecha_hora) %>%
  group_by(estacion) %>%
  mutate(
    # stats::filter, no dplyr::filter (mismo nombre, función distinta)
    media_8h = as.numeric(stats::filter(media, rep(1 / 8, 8), sides = 1))
  ) %>%
  ungroup()


max_8h_dia <- ozono_8h %>%
  mutate(dia = as_date(fecha_hora)) %>%
  group_by(estacion, dia) %>%
  summarise(
    max_8h = if (all(is.na(media_8h))) NA_real_ else max(media_8h, na.rm = TRUE),
```

```

    horas_validas = sum(!is.na(media_8h)),
    .groups = "drop"
)

ggplot(max_8h_dia, aes(x = dia, y = max_8h, color = estacion)) +
  geom_line() +
  geom_hline(yintercept = 100, linetype = "dashed") + # guía OMS 2021: 100 µg/m³
  theme_minimal() +
  labs(title = "Máximo diario de la media móvil de 8 h",
       x = NULL, y = "O3 (µg/m³)")

```



```

source(here::here("clases/clase7/mapa.R"))

```

Warning: package 'htmlwidgets' was built under R version 4.6.1

```

mapa

```




Figure 1: Ozono en Montevideo, ene-abr 2024

9. Patrones de faltantes

Tres tipos de faltante en una serie de sensor:

a) explícito: la fila existe, o3 es NA

b) en rachas: muchos NA consecutivos -> sensor caído o en mantenimiento

c) implícito: la fila no existe (el minuto no está en el archivo)

Eliminar NA sin mirar esto borra evidencia sobre el proceso de medición.

9.1 Faltantes explícitos por estación


```
ozono_limpio %>%
  group_by(estacion) %>%
  summarise(
    n_filas = n(),
    n_na     = sum(is.na(o3)),
    prop_na  = mean(is.na(o3)),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 4
  estacion      n_filas  n_na prop_na
  <chr>         <int> <int>   <dbl>
1 Colon         126378 13549  0.107
2 Curva de Maronias 165548 22610  0.137
```

```
## 9.2 ¿Cuándo faltan? Proporción de NA por día
na_dia <- ozono_limpio %>%
  mutate(dia = as_date(fecha)) %>%
  group_by(estacion, dia) %>%
  summarise(prop_na = mean(is.na(o3)), .groups = "drop")

ggplot(na_dia, aes(x = dia, y = prop_na)) +
  geom_col(fill = "grey40") +
  facet_wrap(~ estacion, ncol = 1) +
  theme_minimal() +
  labs(title = "Proporción de minutos sin dato, por día y estación",
       x = NULL, y = "Proporción de NA")
```

Proporción de minutos sin dato, por día y estación



```
## 9.3 Rachas de NA consecutivos (rle = run length encoding)
rachas <- ozono_limpio %>%
  arrange(estacion, fecha) %>%
  group_by(estacion) %>%
  reframe({
    r <- rle(is.na(o3))
    tibble(faltante = r$values, largo = r$lengths)
  })
```

```

rachas %>%
  filter(faltante) %>%
  mutate(tipo = cut(largo, breaks = c(0, 1, 10, 60, 1440, Inf),
                    labels = c("1 min", "2-10 min", "11 min-1 h", "1 h-1 día", "> 1 día"))) %>%
  count(estacion, tipo, name = "n_rachas")

```

```

# A tibble: 8 x 3
  estacion      tipo      n_rachas
  <chr>         <fct>    <int>
1 Colon        2-10 min      3
2 Colon        11 min-1 h     3
3 Colon        1 h-1 día    33
4 Colon        > 1 día      1
5 Curva de Maronias 2-10 min      3
6 Curva de Maronias 11 min-1 h     8
7 Curva de Maronias 1 h-1 día    28
8 Curva de Maronias > 1 día      1

```

Lectura: muchas rachas de 1 min = ruido de transmisión; pocas rachas > 1 día

= sensor fuera de servicio. Son mecanismos distintos y se tratan distinto.

```

## 9.4 Faltantes implícitos: minutos que no están en el archivo
ozono_limpio %>%
  group_by(estacion) %>%
  summarise(
    primero = min(fecha),
    ultimo = max(fecha),
    esperados = as.numeric(difftime(max(fecha), min(fecha), units = "mins")) + 1,
    presentes = n_distinct(fecha),
    .groups = "drop"
  ) %>%
  mutate(implicitos = esperados - presentes,
         prop_implicitos = implicitos / esperados)

```

```

# A tibble: 2 x 7
  estacion      primero      ultimo      esperados presentes
  <chr>         <dtm>         <dtm>         <dbl>      <int>
1 Colon        2024-01-01 00:00:00 2024-04-29 23:59:00 172800 126378
2 Curva de Maronias 2024-01-01 00:00:00 2024-04-29 23:59:00 172800 165548
# i 2 more variables: implicitos <dbl>, prop_implicitos <dbl>

```